Projet: ANOVA Phylogénétique

Présentation du Mercredi 10 Jan. 2024

Alizée Geffroy, Louis Lacoste, encadrés par Mélina Gallopin et Paul Bastide

M2 MathSV Université Paris-Saclay

Sommaire

1. Rappel du contexte et enjeux du projet

2. Conclusions et perspectives

3. Références et appendices



Idée structure

TODO Supprimer cette slide temporaire intro/contexte: biologique avec l'exemple de Chen (mettre l'arbre) + figure de l'article ? -i trouver les gènes différentiellement exprimés

Il existe déjà des méthodes statistiques pour cette problématique (EVEmodel ? State of the Art)

Transition avec le pourquoi du projet, trouver d'autres méthodes statistiques, adaptées de méthodes classiques qui pourraient bien marcher

Méthode pas par nous : 1 slide par tiret - Reprendre la forme matricielle de l'ANOVA phylo (mettre en rouge les diffs) - Présenter le MB qui évolue sur l'arbre + lien matrice K - Mettre la statistique de test (mettre en rouge la projection (donc diffs))

Transition vers notre travail - Mettre la formule avec erreur de mesure avec justification de l'ajout de l'erreur de mesure, formule transfo V_{λ} , pointer la limite qui est l'erreur dûe à l'estimation du λ Méthode par nous :

Cattantle de la constanta de l

questions posables

- comment obtenir la stat de test pour anova phylo (Cholesky) - en quoi c'est un modèle mixte pour Satterthwaite ? - calcul de la Hessienne optim vs formule analytique, mettre formule analytique



Rappel du contexte et enjeux du projet

Contexte biologique

- Un arbre phylo avec plusieurs espèces
- Un trait quantitatif présent chez ces espèces
- ullet Représenté par un paramètre μ

Typiquement un gène dont on mesure l'expression. Dans **Gomez-Mestre**, **Pyron**, **and Wiens** (2012) ces méthodes sont utilisées pour répondre à des questions d'évolution et d'ordre d'apparition de caractères chez les *Anoures*.



ANOVA vs ANOVA phylogénétique

$$Y = X\beta + \sigma E$$
 où $X = (1, 1_2, ..., 1_K)$ et $\beta = (\mu_1, \beta_2, ..., \beta_K)^T$

Anova

Anova phylogénétique

$$\boldsymbol{E} \sim \mathcal{N}(0_n, \boldsymbol{Id})$$

$$\boldsymbol{E} \sim \mathcal{N}(0_n, \boldsymbol{V})$$

Estimateur du max. de vraisemblance

$$\hat{\beta} = (\boldsymbol{X}^{T}\boldsymbol{X})^{-1}\boldsymbol{X}^{T}\boldsymbol{Y}$$

$$\hat{\sigma}^{2} = \frac{1}{n-p}(\boldsymbol{Y} - \boldsymbol{X}\hat{\beta})^{T}(\boldsymbol{Y} - \boldsymbol{X}\hat{\beta})$$

$$\hat{\beta}_{phylo} = (\boldsymbol{X}^{T}\boldsymbol{V}^{-1}\boldsymbol{X})^{-1}\boldsymbol{X}^{T}\boldsymbol{V}^{-1}\boldsymbol{Y}$$

$$\hat{\sigma}_{phylo}^{2} = \frac{1}{n-p}(\boldsymbol{Y} - \boldsymbol{X}\hat{\beta})^{T}\boldsymbol{V}^{-1}(\boldsymbol{Y} - \boldsymbol{X}\hat{\beta})$$

Objectif: Comparer les méthodes Anova et Anova phylogénétique

⁰Pour l'ANOVA Phylogénétique, nos références sont

bastideContinuousTraitEvolution et Bastide, Mariadassou, and Robin 2022 et pour

l'ANOVA, Bel et al. n.d.

Différents types de groupes

On forme des groupes en lien avec la phylogénie.

Figure 1: Arbre phylogénétique et groupes concordants

On forme des groupes qui ne sont **pas phylogénétiques**.

Figure 2: Arbre phylogénétique et groupes non concordants



Les résultats, 1

Figure 3: Avec de la variabilité purement phylogénétique

Les résultats, 2

Figure 4: Avec de la variabilité phylogénétique et d'erreur de mesure



Ce qu'il se passe vraiment

L'observation se présente sous la forme suivante si réécrite en tant que modèle à effets mixtes :

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}_{\mathbf{Z}\boldsymbol{\mu}+\boldsymbol{\epsilon}}$$

avec
$$\boldsymbol{Z}u \sim \mathcal{N}(0, \sigma_{phylo}^2 V)$$
, $\epsilon \sim \mathcal{N}(0, \sigma_{mesure}^2 \boldsymbol{Id})$ et $Var(\boldsymbol{E}) = \sigma_{phylo}^2 (V + \lambda \boldsymbol{Id})$ où $\lambda = \frac{\sigma_{mesure}^2}{\sigma_{phylo}^2}$

Les méthodes d'ANOVA phylogénétique telles qu'implémentées dans phylolm estiment les paramètres σ^2_{mesure} d'erreur de mesure et σ^2_{phylo} de variabilité dûe à la phylogénie.

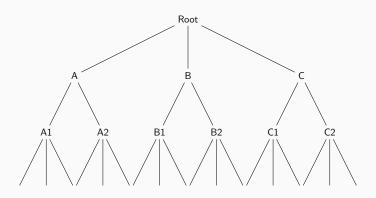
Mais une fois estimé, lors du test de Fisher les paramètres sont considérés comme si non estimés.

Le but ici est donc d'utiliser l'approximation de Satterthwaite (1946) afin de calculer les degrés de libertés du test de loi de Fisher à réaliser.



Conclusions et perspectives

Avec des données individuelles



Le package phylolimma¹ permet de compléter un arbre existant en ajoutant les sous-branches au bout.

Nous voulons obtenir une méthode d'estimation des paramètres et l'implémenter sur ce type d'arbre.

Perspectives

- Implémenter le test statistique correspondant à l'approximation de Satterthwaite.
- Implémenter le test de ratio de log-vraisemblance.
- Implémenter avec plusieurs individus par espèces

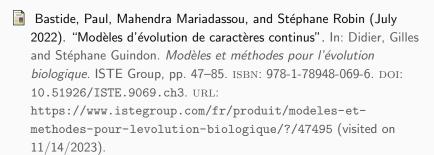
Objectif principal

Trouver un test robuste et rapide, applicable à des milliers de données d'expressions de gènes mesurées dans une expérience RNAseq typique.



Références et appendices

References



Bel, L et al. (n.d.). Le Modèle Linéaire et ses Extensions.



References ii

Gomez-Mestre, Ivan, Robert Alexander Pyron, and John J. Wiens (2012). "Phylogenetic Analyses Reveal Unexpected Patterns in the Evolution of Reproductive Modes in Frogs". In: Evolution 66.12, pp. 3687–3700. ISSN: 1558-5646. DOI: 10.1111/j.1558-5646.2012.01715.x. URL: https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1558-5646.2012.01715.x (visited on 11/13/2023).

Satterthwaite, F. E. (Dec. 1946). "An Approximate Distribution of Estimates of Variance Components". In: Biometrics Bulletin 2.6, p. 110. ISSN: 00994987. DOI: 10.2307/3002019. JSTOR: 10.2307/3002019. URL: https://www.jstor.org/stable/10.2307/3002019?origin=crossref (visited on 01/08/2024).



Code pour les simulations i

Le code pour les simulations est disponible sur notre dépôt GitHub :

https:

//github.com/Polarolouis/anova-phylogenetique-projet-msv/